



ChatPDF-RAG : pipeline local de question-réponse sur documents PDF avec analyse multimodale

KNIFE Arthur¹

¹ ESME Sudria, Paris, France

Contexte historique et technique

Depuis l'émergence des Large Language Models (LLM), la question de leur fiabilité documentaire est centrale : interrogés hors de leur corpus d'entraînement, ils produisent des hallucinations factuelles.

Le paradigme Retrieval-Augmented Generation (RAG), introduit par Lewis et al. (2020) [1], a redéfini la Q&A sur documents en couplant un LLM génératif à un index sémantique externe.

Les enjeux actuels du RAG en production sont triples :

- Confidentialité — exécution locale vs cloud propriétaire.
- Robustesse — qualité de récupération, contexte long.
- Multimodalité — schémas, tableaux et figures PDF.

Le projet ChatPDF-RAG répond à ces enjeux en proposant un pipeline 100 % local, instrumenté pour mesurer la qualité des réponses générées sur un corpus PDF arbitraire.

Définitions et Concepts

RAG

: Retrieval-Augmented Generation. Injection dans le prompt d'extraits documentaires récupérés par similarité [1].

Embeddings

: représentations vectorielles denses du texte (Sentence-BERT, Reimers & Gurevych 2019 [2]).

FAISS

: librairie de recherche vectorielle ANN développée par Meta (Johnson et al., 2019 [3]).

Chunking parent/enfant

: stratégie « small-to-big » — recherche sur petits chunks, génération sur leurs parents plus larges.

VLM

: Vision-Language Model. Décrit schémas et figures pour rendre les éléments graphiques interrogeables.

Méthodes

1. Pipeline RAG textuel

Chaque PDF est segmenté en deux niveaux par RecursiveCharacterTextSplitter :

- Parent = 800 car. (contexte LLM)
- Enfant = 150 car. (granularité de recherche)

Embeddings all-MiniLM-L6-v2 (384 dim.) normalisés, indexés dans FAISS [3].

À la requête : top-k enfants → remontée aux parents (small-to-big) → prompt RAG → Ollama (llama3.2, mistral, phi4...).

Historique conversationnel : les 3 derniers tours sont concaténés au prompt pour le suivi contextuel.

2. Analyse multimodale ROUGE / similarité cosinus

Les PDF techniques contiennent des schémas et figures peu exploités par les RAG textuels classiques.

Heuristique PyMuPDF : détection des pages candidates contenant images bitmap ou dessins vectoriels.

Seules ces pages sont rendues en image et envoyées au VLM (llama3.2-vision, llava, minicpm-v...) pour produire une description structurée [5].

Le texte généré est indexé dans le même FAISS, avec métadonnée content_type=image — la provenance graphique reste traçable dans la réponse finale.

Cette stratégie sélective réduit fortement le coût d'inférence vision face à un balayage exhaustif.

3. Évaluation automatique

Le test automatique est effectué sur un jeu de données de référence electricite.pdf : N questions et réponses attendues.

Chaque question est rejouée n fois (n ∈ [1,10]) pour capturer la stochasticité de la génération LLM.

Métriques calculées par run :

- ROUGE-1 / ROUGE-2 / ROUGE-L [4]
- Similarité cosinus d'embeddings (MiniLM)
- Temps de réponse
- Taux de refus (« cannot find »)

Agrégation : moyenne et écart-type — l'écart-type quantifie la stabilité du modèle face à la même question.

Résultats

Comparaison de modèles locaux Ollama sur le corpus electricite.pdf — n = 3 répétitions par question.

Tendances observées :

- llama3.2 (3B) — meilleur équilibre vitesse / qualité, ROUGE-1 ≈ 0,35, similarité ≈ 0,78.
- mistral (7B) — meilleure formulation, latence × 2.
- phi4 (14B) — précision supérieure mais > 25 s/requête sur CPU.
- gemma3 — taux de refus plus élevé sur questions hors-corpus.

Effet du chunking parent/enfant :

La stratégie small-to-big améliore la similarité moyenne de +0,08 à +0,12 par rapport à un chunking simple de 800 caractères, en conservant un contexte de prompt exploitable par le LLM.

Effet de l'analyse multimodale :

Sur les questions portant sur des schémas électriques, l'activation du VLM fait chuter le taux de refus de ~60 % à <15 %, au prix d'une indexation initiale 5 à 10× plus longue.

Stabilité : l'écart-type de similarité reste < 0,05 sur la plupart des questions — le pipeline est reproductible malgré la température non nulle d'Ollama.

Conclusions et Perspectives

Un pipeline RAG 100 % local, combinant chunking hiérarchique, FAISS et VLM optionnel, atteint un niveau de qualité utilisable sur des PDF techniques tout en préservant la confidentialité des documents.

L'instrumentation d'évaluation (ROUGE + cosinus + n répétitions) permet de comparer objectivement les modèles Ollama et d'arbitrer le compromis qualité / latence selon le matériel cible.

Perspectives :

- Reranking croisé (cross-encoder) avant injection au LLM pour réduire le bruit du top-k.
- Hybridation BM25 + dense pour les requêtes lexicales strictes.
- GraphRAG (Edge et al., 2024 [6]) — indexation par graphe d'entités pour les questions globales.
- Quantification GGUF des VLM pour rendre la pipeline vision viable sur GPU grand public.
- Élargissement du jeu d'évaluation à des PDF multi-domaines (juridique, médical, scientifique).

Au-delà des métriques automatiques, une évaluation humaine (Likert-scale, A/B blind tests) reste indispensable pour caractériser la pertinence perçue des réponses.

Références

- [1] Lewis, P. et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. NeurIPS.
[2] Reimers, N. & Gurevych, I. (2019). Sentence-BERT: Sentence Embeddings using Siamese BERT Networks. EMNLP.
[3] Johnson, J., Douze, M. & Jégou, H. (2019). Billion-scale similarity search with GPUs. IEEE Transactions on Big Data.
[4] Lin, C.-Y. (2004). ROUGE: A Package for Automatic Evaluation of Summaries. ACL Workshop.